



CultureQuest - Platformă mobilă de explorare urbană cu recomandări personalizate prin învățare federată

Andrei Cozma

Coordonatori științifici:

Prof. dr. ing. Ciprian-Mihai Dobre

Prof. dr. ing. Radu-Ioan Ciobanu

1 iulie 2026

Motivație

Problema:

- Recomandări personalizate → date stocate central
- Utilizatorul alege: *confidențialitate* sau *personalizare*

Consecințe:

- Locații GPS, preferințe → profil comportamental pe server
- Fără personalizare reală → popularitate amplifică aglomerarea

Propunere: confidențialitate și personalizare *nu se exclud*:
antrenare locală pe dispozitiv

State of the art

Aplicații de explorare urbană:

- Google Maps, TripAdvisor: personalizare centralizată
- izi.TRAVEL, GetYourGuide: rute fixe, fără personalizare
- Niciuna: rute personalizate + privacy by design + gamificare

Federated Learning (FL) în recomandări:

- FedAvg: standard de facto; cere clienți simultan disponibili
- FedAsync: asincron cu discount de vechime
- DP (NbAFL): zgomot Gaussian

Golul: FL asincron cu DP pe turism cultural, neabordat

Soluție propusă

Patru componente integrate:

- Obiective culturale pe hartă
- Quest-uri prin geofencing (< 100 m)
- Rute generate dinamic, personalizate prin FL
- Comunitate: recenzii, povești, propuneri de obiective, moderare

Privacy by design: interesele sunt învățate local din interacțiuni, fără ca datele să părăsească dispozitivul

Arhitectura sistemului

Strat	Tehnologie
Mobil	Flutter + Riverpod
Backend	FastAPI (Python)
Date	MongoDB
FL	Redis
Rutare	OSRM

Trei fluxuri:

- Hartă + rute: obiectivele din MongoDB evaluate prin modelul din Redis
- Agregare FL: delta client → ponderi actualizate în Redis
- Comunitar: recenzii, povești, quests prin moderare

O singură bază de cod Dart → Android + iOS; cache local în SharedPreferences

Modelul de personalizare

MLP $22 \rightarrow 32 \rightarrow 16 \rightarrow 1$; 1 281 parametri; inferență $\approx 39 \mu\text{s}$ pe laptop

Grup (dim.)	Conținut
Interese [0–5]	artă, arhit., istorie, gastron., natură, muzică
Tip [6–13]	muzeu, monum., parc, galerie, restaur., piață, clădire, altele
Temporal [14–16]	isOpen, isWeekend, ora/24
Spațial [17–21]	rang dist., potrivire interese, în rută, poziție, lungime

leșire: scor $\in [0, 1] \rightarrow$ scăzut ($< 0,4$) · mediu · ridicat ($\geq 0,7$)

Rulează pe **server** (evaluare candidați) și pe **dispozitiv** (scor popup)

Generarea rutelor personalizate

Algoritmul (pe server):

- 1 Candidați: obiective în **raza 10 km**
- 2 Scoring: **80% MLP + 20% proximitate** → top 10
- 3 Traseu **greedy**: $\min(\text{dist} - \lambda \cdot \text{match})$, λ configurat de utilizator
- 4 Durata per oprire: scalată $\pm 25\%$ de scorul MLP
- 5 Traseu real: **OSRM** (walking / driving)

Pre-antrenarea modelului global

Problema cold-start: la prima utilizare, niciun dispozitiv nu a contribuit încă la modelul global

Pre-antrenare (741k înreg., Foursquare, Yelp)	[0,595; 0,850]; blocat la medie
Fine-tuning (+16k sintetice + $3 \times$ scoruri $\leq 0,4$)	[0,050; 0,841]; +211%

Fără fine-tuning: predicție 0,70–0,75 indiferent de input

→ etichete concentrate spre valori mari (Yelp: 60% recenzii 4–5 stele;

Foursquare: fix 0,70) + `isOpen=0` absent

Antrenare locală

Etichete buffer:

Eveniment	Etichetă
Sheet obiectiv deschis	0,3
Adăugat la rută / Quest încercat	0,5
Navigație pornită	0,6
Quest sugerat	0,80
Poveste trimisă	0,85
Quest completat	0,9
Rating explicit (stele)	stele / 5

Procedura (FedAvg client):

- Declanșare automată după 15 interacțiuni în buffer
- 5 epoci SGD ($\text{lr} = 0,01$), gradient clipping $\text{L2} = 1$
- Buffer persistat în SharedPreferences
- Trimite doar delta ponderilor, nu interacțiunile brute

Agregare asincronă, concurență și confidențialitate

FedAsync: delta ponderată cu $\frac{1}{1+s}$; clienți „stale” contribuie mai puțin

Redis lock: SET NX PX $\rightarrow$ un singur client în ciclul read–aggregate–write; TTL = 5 s

Differential Privacy (NbAFL):

- **Client:** clamp $[-1, +1] + \mathcal{N}(0, 0,01)$ per coordonată
- **Server:** clipping $L2 \leq 1$ pe delta primită

Evaluare

1. Corectitudine funcțională: demo: hartă, rute, quests, recenzii, FL local, offline (+ teste unitare model FL)

2. Performanța FL: 10 000 clienți sintetici, 600 runde, ≈ 23 ms/rundă (antrenare + agregare):

	FedAsync	Fără discount
BCE finală	0,480	0,506
Reducere	-30,9%	-27,2%
Pondere medie stale	0,489	1,000

3. Scalabilitate: 0 erori la ≤ 10 cereri FL simultane; degradare la 20 (TTL lock)

Scoruri pentru obiective după 600 runde



Limitări

- **Validare pe clienți sintetici:** comportamentul în producție rămâne neverificat pe date reale
- **Proximitate exclusiv în foreground:** GPS se oprește în background; soluție: geofencing nativ OS
- **Scalabilitate Redis lock:** 8/20 cereri FL simultane respinse; soluție: coadă de lucru (Redis Queue)
- **FedPer exclus:** straturi personalizate per utilizator necesită stocare locală permanentă

Concluzii

Ce am construit: aplicație Flutter end-to-end cu flux FL complet (pre-antrenare → FedAsync + DP)

Ce am obținut:

- Rute personalizate diferite per utilizator; quests prin geofencing
- Comunitate activă: recenzii, povești, propuneri de obiective
- Interese învățate local; datele nu părăsesc dispozitivul



Ce urmează: validare pe utilizatori reali; FedPer; FedBuff (agregare cu buffer); fotografii obiective

Întrebări

Mulțumesc pentru atenție! Întrebări?

Cuvinte cheie:

- Explorare Urbană
- Generare de Rute · OSRM
- Învățare Federată · FedAsync · MLP
- Confidențialitate Diferențială/prin Design



Algoritmul de generare a rutei

1. Filtrare candidați (raza 10 km)

scor inițial = $FL \times 0,8 + (1 - d_{\text{norm}}) \times 0,2 \rightarrow \text{top } 2n \text{ candidați}$

2. Greedy nearest-neighbour

La fiecare pas: $\text{argmin}_l [\text{dist}(\text{crt}, l) - \lambda \cdot \text{match}(l)]$

$\text{match}(l)$ = fracție categorii obiectiv $\cap$ interese utilizator; λ configurat de utilizator

Se oprește când bugetul de timp e depășit sau s-a atins n_{max} opriri

3. Scalare timp vizită cu MLP

$t = t_{\text{baza}} \times (0,75 + 0,5 \times \text{FL_score})$; t_{baza} pe tip: muzeu 70 min, monument 20 min ...

4. Traseu real via OSRM (walking / driving)

Cold-start: ce vede un utilizator nou?

1. Onboarding → utilizatorul selectează interesele (artă, arhitectură, ...)

Intră direct în vectorul de caracteristici [0–5]; nicio interacțiune necesară

2. Model global descărcat (GET /model/global)

Model pre-antrenat pe Foursquare + Yelp; recomandările sunt utile de la prima sesiune

3. Buffer de interacțiuni se umple

1 intrare / obiectiv / rundă (deduplicat); după **15 interacțiuni** → rundă FL declanșată automat

4. Prima contribuție FL

Antrenare locală pe dispozitiv → delta trimis la server → model actualizat; personalizarea se construiește progresiv

Sursele de date pentru pre-antrenare

Sursă	Tip	Etichetă
Foursquare (3 seturi LBSN)	check-in	0,70; 0,75 recom.; 0,90 repetate
Yelp	recenzii 1–5 stele	stele / 5
Sintetice (is0pen=0)	generate artificial	0,10

Total: 741.618 înregistrări; $MSE_{val} = 0,023$; predicții blocate în $[0,595; 0,850]$

Fine-tuning: +16k sintetice is0pen=0; $3\times$ suprareprezentare etichete $\leq 0,4$
 → interval lărgit la $[0,050; 0,841]$ (+211%)

Taxonomia FL și poziționarea CultureQuest

Tipul de partiție a datelor:

- **HFL** (Orizontal): toți clienții antrenează același model pe același spațiu de 22 caracteristici; diferă doar interacțiunile locale
- **VFL** și **FTL**: excluse; nu există suprapunere de caracteristici diferite între clienți

Tipul de desfășurare:

- **Cross-Device**: mii de telefoane, conectate intermitent, cu volum mic de date locale
- **Cross-Silo**: exclus; nu există organizații cu date partajate

CultureQuest: **HFL Cross-Device asincron** cu DP (NbAFL)

De ce FedAsync și nu FedProx / SCAFFOLD / FedDyn?

FedProx, SCAFFOLD, FedDyn presupun o **cohortă sincronă** de clienți per rundă.

CultureQuest procesează un client pe rând → nu există cohortă → mecanismele de corecție nu au referință.

Algoritm	Sincron	Mecanism	Compatibil
FedAvg	Da	Medie ponderată	Da (local)
FedAsync	Nu	Discount staleness $1/(1 + s)$	Da
FedProx	Da	Termen proximal	Nu
SCAFFOLD	Da	Variabilă de control	Nu
FedDyn	Da	Regularizator dinamic	Nu

Differential Privacy în detaliu

Mecanismul DP (NbAFL, pe client):

- 1 Clampare per coordonată: $\delta_i \in [-\tau, \tau]$, $\tau = 1 \rightarrow$ mărginește sensibilitatea
- 2 Zgomot Gaussian: $\tilde{w} = w_{\text{global}} + \text{clip}(\delta, \tau) + \mathcal{N}(0, (\sigma\tau)^2)$, $\sigma = 0,1$

Mecanisme corelate (scopuri diferite):

- **Client, în SGD:** limitare L2 gradient $\|g\|_2 \leq 1 \rightarrow$ stabilitate antrenare, nu DP
- **Server, la agregare:** limitare L2 deltă $\|\delta\|_2 \leq \tau \rightarrow$ robustețe față de actualizări adversariale, nu DP

Zgomotul adăugat pe client $\rightarrow$ serverul primește ponderi din care delta reală nu mai poate fi reconstituită

Scalabilitate: testul de concurență FL

Cereri simultane	Succes	Erori	Lat. medie (ms)	Lat. p95 (ms)
1	1	0	6,5	6,5
5	5	0	622,6	923,5
10	10	0	1.384,1	2.442,2
20	12	8	2.064,9	3.076,1

Concluzie: lock Redis → 0 erori până la 10 cereri simultane
La 20: 8/20 cereri respinse (TTL lock expirat); fără corupere date
Soluție: coadă (Redis Queue) → elimină lock-ul din calea HTTP

Consum de baterie și proximitate în foreground

Curent: geofencing manual (geolocator); GPS activ doar în foreground

→ quest-urile nu se activează când aplicația e în background

Alternativă: geofencing nativ OS

- iOS: *Region Monitoring*; Android: *Geofence API*
- OS gestionează GPS; notifică doar la traversarea razei → consum redus

Bibliografie

H. B. McMahan et al., *Communication-Efficient Learning of Deep Networks from Decentralized Data*, AISTATS, 2017.

C. Xie et al., *Asynchronous Federated Optimization*, OPT Workshop NeurIPS, 2019.

K. Wei et al., *Federated Learning with Differential Privacy: Algorithms and Performance Analysis (NbAFL)*, IEEE TIFS, 2020.

Q. Yang et al., *Federated Machine Learning: Concept and Applications*, ACM TIST, 2019.

P. Kairouz et al., *Advances and Open Problems in Federated Learning*, Foundations and Trends in ML, 2021.

T. Li et al., *Federated Optimization in Heterogeneous Networks (FedProx)*, MLSys, 2020.

S. P. Karimireddy et al., *SCAFFOLD: Stochastic Controlled Averaging for Federated Learning*, ICML, 2020.

Bibliografie (cont.)

D. A. E. Acar et al., *Federated Learning Based on Dynamic Regularization (FedDyn)*, ICLR, 2021.

M. G. Arivazhagan et al., *Federated Learning with Personalization Layers (FedPer)*, arXiv, 2019.

J. Nguyen et al., *Federated Learning with Buffered Asynchronous Aggregation (FedBuff)*, AISTATS, 2022.